


Работа с пропусками и переменными

Алексей Кузьмин
Директор разработки в «Домклик»



Алексей Кузьмин


О спикере:

- Директор разработки, «Домклик»
- Исполнительный директор по исследованию данных в «Домклик»
- Руководжу направлением работы с данными и машинного обучения
- Под управлением 9 команд ~ 60 человек
- Был сотрудником АBBYY, где занимался распознаванием языков со сложной письменностью
- Выпускник мехмата МГУ




План занятия

- 1 Работа с пропущенными значениями
- 2 Масштабирование переменных
- 3 Обработка категориальных переменных



Работа с пропущенными значениями



1

Проблематика

Пропущенные значения* в данных снижают **статистическую мощность**** (предсказательную силу) датасета, так как могут вести к систематическим ошибкам

*Алгоритмы по-разному воспринимают пропущенные значения

**Статистическая мощность — чем выше мощность статистического теста, тем меньше вероятность совершить ошибку второго рода

Как с ЭТИМ БЫТЬ

Удаление:


- столбцов, содержащих нулевое значение (потеря информации)
- строк, в которых атрибут равен нулевому значению (потеря информации)



Как с ЭТИМ БЫТЬ


Другие методы:

- статистический подход (среднее, медиана и т. д.)
- создание переменной индикатора/флага
- восстановление пропусков на основе моделей, интерполяции, аппроксимация
- заполнение с помощью логических правил



Статистический подход

Статистический подход — это замена всех нулевых значений на **среднее значение по столбцу** (максимальное, минимальное, медиану, моду или один из перцентилей)



Статистический подход

Плюсы:

- быстро
- очень просто

Минусы:

- не учитывает никакие зависимости в данных
- создаёт дрейф в данных*

*Дрейф в данных — различие распределения по переменной в обучающей и тестовой выборке

Создание переменной индикатора

Indicator/Flag method – замена пропущенных значений* и создание новой переменной индикатора (принимает значение 1 при наличии пропуска и 0 в остальных случаях)



*Необязательно заменять значение на 0, лучше выбрать число, которое отличается от встречающихся в столбце

Создание переменной индикатора*

Плюсы:

- быстро
- очень просто


Минусы:

- не учитывает никакие зависимости в данных
- создаёт ещё один параметр для модели

*Разные модели по-разному будут реагировать на этот метод

Восстановление пропусков на основе моделей

- Различные интерполяции
- Аппроксимация аналитической функцией
- Линейная регрессия
- Логистическая регрессия
- Деревья решений (случайный лес и т. д.)
- k-NN — метод k-ближайших соседей



Восстановление пропусков на основе моделей

Плюсы:

- можно учесть сложные зависимости в данных

Минусы:

- сложно применять
- может сильно усложнить процесс переобучения
- может увеличить время скоринга/переобучения

Заполнение с помощью логических правил

Пример

Пусть у вас есть пропуски в переменной, отвечающей за замеры температуры. Из физики и банальной логики известно, что в большинстве случаев температура изменяется плавно и имеет смысл для заполнения пропусков брать среднее соседних по времени значений, а не среднее по всему столбцу.

Плюсы:

- можно учесть сложные зависимости в данных

Минусы:

- сложно применять
- может сильно усложнить процесс переобучения
- может увеличить время скоринга/переобучения

Масштабирование переменных




2

Основные методы масштабирования

→ Нормализация:

- десятичное масштабирование (decimal scaling)
- минимаксная нормализация (min-max normalization)
- нормализация средним (Z-нормализация)
- отношение

→ Логарифмирование



Десятичное масштабирование

Нормализация производится перемещением десятичной точки на число разрядов, соответствующее порядку числа:

$$x'_i = x_i / 10^n$$

где n — число разрядов в наибольшем наблюдаемом значении.

Например, пусть имеется набор значений:

-10, 201, 301, -401, 501, 601, 701

Каждое наблюдаемое значение делим на 1 000 и получаем:

-0.01, 0.201, 0.301, -0.401, 0.501, 0.601, 0.701

Десятичное масштабирование

Плюсы:

- очень быстро
- очень просто
- надёжно

Минусы:

- Результирующие значения будут занимать не всегда один и тот же диапазон значений. В этом легко убедиться, убирая часть значений из примера с предыдущего слайда

Минимаксная нормализация

Минимаксная нормализация – преобразование исходного набора данных в диапазон [0..1] с помощью линейного преобразования:

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$$

Если мы захотим преобразовать данные в произвольный диапазон [a, b]:

$$X' = a + \frac{X - X_{min}}{X_{max} - X_{min}}(b - a)$$

Минимаксная нормализация

Плюсы:

- быстро
- мы всегда знаем, в каком диапазоне находятся данные $[0, 1]$ (или $[a, b]$)
- просто

Минусы:

- плохой результат при наличии аномальных значений (выбросов)

Нормализация средним

Нормализация средним — это линейное преобразование данных на основе среднего значения и стандартного отклонения — деление разницы между переменной и средним значением на стандартное отклонение:

$$x'_i = (x_i - \bar{X}) / \sigma_x$$

*Полученные величины часто называют Z-оценками

Нормализация средним

Плюсы:

- хорошо справляется с аномальными значениями


Минусы:

- заранее неизвестный интервал
- чуть медленнее
- чуть сложнее в понимании и применении

Логарифмирование


Логарифмирование помогает снизить неоднородность разброса значений переменной

Гистограмма Y\$таж



$\log(x)$

Гистограмма I\$і



Логарифмирование

Плюсы:

- быстро

Минусы:

- не всегда подходит (только для определённых распределений)
- надо подбирать основание алгоритма
- если распределение меняется, этот метод не подходит

Обработка категориальных переменных




3

Способы обработки категориальных переменных

- Кодирование метки — label encoding
- Порядковое кодирование
- Прямое кодирование — one-hot (dummy) encoding
- **От интервалов к числам — bins to number**
- С помощью бизнес-логики
- Целе-вероятностное кодирование — target encoding

Кодирование метки



Плюсы:

- не растёт размерность


Минусы:

- создаются ложные интерпретации, например, $VW > Acura$ или $VW + Acura = Honda^*$

*Не для всех моделей это проблема

Порядковое кодирование

Temperature
Hot
Cold
Very Hot
Warm
Hot
Warm
Warm
Hot
Hot
Cold



Temp_Ordinal
3
1
4
2
3
2
2
3
3
1

Плюсы:

- не растёт размерность
- сохраняется порядок

Минусы:

- создаются ложные интерпретации, например, Cold + Warm = Hot*

*Не для всех моделей это проблема

Прямое кодирование

Company name	Price
VW	20000
Acura	10011
Honda	50000
Honda	10000



VW	Acura	Honda	Price
1	0	0	20000
0	1	0	10011
0	0	1	50000
0	0	1	10000

Плюсы:

- не создаётся ложных интерпретаций

Минусы:

- когда категорий много, сильно растёт размерность

От интервалов к числам

User_ID	Product_ID	Gender	Age
1000001	P00069042	F	0-17
1000001	P00248942	F	0-17
1000001	P00087842	F	0-17
1000001	P00085442	F	0-17
1000002	P00285442	M	55+
1000003	P00193542	M	26-35
1000004	P00184942	M	46-50
1000004	P00346142	M	46-50
1000004	P0097242	M	46-50
1000005	P00274942	M	26-35
1000005	P00251242	M	26-35

Среднее
→

User_ID	Product_ID	Gender	Age	New_Age	Occ
1000001	P00069042	F	0-17	14	
1000001	P00248942	F	0-17	14	
1000001	P00087842	F	0-17	14	
1000001	P00085442	F	0-17	14	
1000002	P00285442	M	55+	60	
1000003	P00193542	M	26-35	30	
1000004	P00184942	M	46-50	47	
1000004	P00346142	M	46-50	47	
1000004	P0097242	M	46-50	47	
1000005	P00274942	M	26-35	30	
1000005	P00251242	M	26-35	30	

Верхняя
и нижняя
граница
→

User_ID	Product_ID	Gender	Age	Lower_Age	Upper_Age
1000001	P00069042	F	0-17	0	17
1000001	P00248942	F	0-17	0	17
1000001	P00087842	F	0-17	0	17
1000001	P00085442	F	0-17	0	17
1000002	P00285442	M	55+	55	80
1000003	P00193542	M	26-35	26	35
1000004	P00184942	M	46-50	46	50
1000004	P00346142	M	46-50	46	50
1000004	P0097242	M	46-50	46	50
1000005	P00274942	M	26-35	26	35
1000005	P00251242	M	26-35	26	35

Обработка с помощью бизнес-логики

Zip Code
110044
110048
110049
110006
110007
110058
110059
110063
110064

Соответствие
индекса
округу

Zip Code	District
110044	South Delhi
110048	South Delhi
110049	South Delhi
110006	North Delhi
110007	North Delhi
110058	West Delhi
110059	West Delhi
110063	West Delhi
110064	West Delhi

Плюсы:

- уменьшается конечная размерность таблицы

Минусы:

- может потеряться часть информации

Целе-вероятностное кодирование*

Levels
HA014
HA001
HA003
HA009
HA015
HA010
HA006
HA017
HA007
HA004
HA005
HA012

Доля таргет-переменной для каждой категории

Response_Rate	New_Level
98%	1
97%	1
93%	1
81%	2
75%	3
73%	3
66%	4
60%	4
49%	5
36%	6
31%	6
28%	7

Можно объединить близкие числа в более крупные категории

*С этим методом надо быть особо внимательными, чтобы не случилась утечка таргета

Итоги



Итоги

- ① Исправить проблемы, связанные с пропущенными значениями, помогают:
- удаление столбцов, содержащих нулевое значение, или строк, в которых атрибут равен нулевому значению
 - статистический подход
 - создание переменной индикатора/флага
 - восстановление пропусков на основе моделей, интерполяции, аппроксимации
 - заполнение с помощью логических правил

- ② Основные методы масштабирования:
- нормализация (десятичное масштабирование, минимаксная нормализация, нормализация средним, отношение)
 - логарифмирование

- ③ Основные способы обработки категориальных переменных:
- кодирование метки
 - порядковое кодирование
 - прямое кодирование
 - от интервалов к числам
 - с помощью бизнес-логики
 - целе-вероятностное кодирование

Спасибо за внимание!

Алексей Кузьмин
Директор разработки в «Домклик»

