


Генерация переменных и feature selection


Алексей Кузьмин
Директор разработки в «ДомКлик»



Алексей Кузьмин


О спикере:

- Директор разработки в «ДомКлик»
- Руководил направлением работы с данными и машинного обучения
- Под управлением ~ 600 человек
- Экс-сотрудник АBBYY, где занимался распознаванием языков со сложной письменностью
- Выпускник мехмата МГУ



План занятия

- 1 Введение
- 2 Генерация признаков
- 3 Методы отбора признаков
- 4 Преобразование признаков



Введение




Введение: зачем всё это


Проклятие размерности – проблема, связанная с экспоненциальным возрастанием количества необходимых для обучения данных, из-за увеличения размерности пространства:



Одно измерение – 5 точек




Два измерения – 25 точек



Три измерения – 125 точек

Введение: зачем всё это

С увеличением размерности пространства некоторые алгоритмы начинают работать хуже:




Методы отбора признаков

Позволяют

- упрощать модели, чтобы повысить возможность интерпретации исследователями или пользователями
- сокращать время тренировки
- уменьшать влияние проклятия размерности
- улучшать обобщение, сокращая переобучение
- фильтровать шумные признаки


Как можно избежать проклятия размерности

Преобразовать признаки:



n – количество примеров
 m – количество признаков

Отобрать признаки:



Генерация признаков



Алгоритм генерации признаков

- Генерация гипотез на основании экспертного мнения, первичного анализа данных
- Решение, какие признаки создавать
- Создание признаков
- Проверка, какие признаки работают с вашей моделью
- Улучшение признаков, если требуется
- Возврат к первому пункту

Генерация временных признаков

Генерацию признаков можно проводить на основании:

- Характеристики момента времени/циклических признаков
 - дни недели
 - праздники/каникулы
 - выходные/рабочие дни
 - перерыв на обед
- Взаимодействия пары признаков, например, расстояния между двумя событиями — созданием заказа и началом сборки

Группировка по полю

Сгруппируем таблицу по полю «Пользователь», преобразуя поле «Город» в столбцы. На пересечениях остаётся количество «Дней посещений»:

User	City	Visit days
1	Roma	1
2	Madrid	2
1	Madrid	1
3	Istanbul	1
2	Istanbul	4
1	Istanbul	3
1	Roma	3

User	Istanbul	Madrid	Roma
1	3	1	4
2	4	2	0
3	1	0	0

Разделение одного поля на несколько признаков

Policy		Type	Level
Corporate L3		Corporate	L3
Personal L3		Personal	L3
Personal L3		Personal	L3
Corporate L2		Corporate	L2
Personal L3		Personal	L1

Есть методы автоматической генерации признаков (Auto-ML)

Например, Featuretools – платформа с открытым исходным кодом для автоматического создания переменных (Feature Engineering):

Why use Featuretools?



Improve your existing workflow

Featuretools works alongside tools you already use to build machine learning pipelines. You can load in pandas dataframes and automatically create meaningful features in a fraction of the time it would take to do manually.

Методы отбора признаков



Методы отбора признаков

Задача — найти подмножество признаков, на котором выбранная модель покажет лучшее качество.

→ Фильтры

Основаны на некоторых показателях, не зависящих от метода классификации, таких как коэффициент корреляции, взаимная информация, F-тест, Хи-квадрат

→ Обёртки

Опираются на информацию о важности признаков полученную от других методов или моделей ML: например, последовательный отбор и последовательное исключение признаков

→ Встроенные в алгоритмы

Выполняют отбор признаков во время процедуры обучения классификатора, и именно они явно оптимизируют набор используемых признаков для достижения лучшей точности: регрессия с L1-регуляризацией, Random Forest, SHAP


Корреляция

Корреляция – статистическая взаимосвязь двух величин. При этом изменения значений одной величины сопутствуют систематическому изменению значений другой величины

Коэффициент корреляции Пирсона:

$$R_{k,p} = \frac{\sum_{i=1}^n (k_i - \hat{k}) \cdot (p_i - \hat{p})}{\sqrt{\sum_{i=1}^n (k_i - \hat{k})^2 \cdot \sum_{i=1}^n (p_i - \hat{p})^2}}$$

Корреляция двух величин – **k** и **p**, измеренных **i** раз



Ковариация

Ковариация – показатель степени изменения двух случайных величин относительно друг друга (в теории вероятностей и математической статистике)

Ковариацией случайных величин **X** и **Y** называют математическое ожидание двух случайных величин **$X - M(X)$** и **$Y - M(Y)$**

$$\text{cov}_{XY} = M[(X - M(X))(Y - M(Y))] = M(XY) - M(X)M(Y)$$

Ковариация и корреляция: разница

Определение	Ковариация — показатель степени зависимости двух случайных величин друг от друга. Более высокое число означает более высокую зависимость	Корреляция — показатель того, насколько сильно связаны эти две переменные, при условии, что другие условия постоянны. Максимальное значение +1, что означает идеальную зависимость
Отношения	Корреляцию можно вывести из ковариации	Корреляция обеспечивает меру ковариации по стандартной шкале. Он выводится путём деления вычисленной ковариации на стандартное отклонение
Значения	Значение ковариации лежит в диапазоне от $-\infty$ до $+\infty$	Корреляция ограничена значениями в диапазоне от -1 до +1
Масштабируемость	Влияет на ковариацию	На корреляцию не влияет изменение шкалы или умножение на константу
Единицы	Ковариация имеет определённую единицу, поскольку она выводится путём умножения двух чисел и их единиц	Корреляция — это безразмерное абсолютное число от -1 до +1, включая десятичные значения

Взаимная информация (mutual information)

MI (переменная x_1 ; таргет) =
Entropy (переменная x_1) – **Entropy** (переменная x_1 ; таргет):

$$Entropy = - \sum p(X) \log p(X)$$

← здесь $p(x)$ –
доля примеров
в данном классе

Чем выше значение MI, тем сильнее связь между этой переменной и таргетом, это говорит о том, что мы должны поместить эту переменную в набор данных для обучения

F-тест (критерий Фишера)

Критерий Фишера применяется при проверке гипотезы о равенстве дисперсий двух генеральных совокупностей, распределенных по нормальному закону. Он является параметрическим критерием.

Пусть в результате наблюдений получены две выборки. По ним вычислены дисперсии S_1^2 и S_2^2 , имеющие f_1 и f_2 степеней свободы. Будем считать, что первая выборка взята из генеральной совокупности с дисперсией σ_1^2 , а вторая — из генеральной совокупности с дисперсией σ_2^2 . Выдвигается нулевая гипотеза о равенстве двух дисперсий,

т. е. $H_0: \sigma_1^2 = \sigma_2^2$ или $\frac{\sigma_1^2}{\sigma_2^2} = 1$. Чтобы отвергнуть эту гипотезу нужно доказать значимость

различия при заданном уровне значимости α .

Значение критерия
вычисляется по формуле:


$$F = \frac{S_1^2}{S_2^2}$$

Очевидно, что при равенстве дисперсий величина критерия будет равна единице

Методы, встроенные в алгоритмы

В алгоритме XGBoost важность переменных может быть измерена следующими способами:


- 1 **gain** — средний прирост по всем разделениям дерева для этой переменной
- 2 **total_gain** — суммарный
- 3 **weight** — кол-во раз использования этой переменной для разделения (используется по умолчанию)
- 4 **cover** — среднее кол-во наблюдений, относящихся к этой переменной
- 5 **total_cover** — суммарное



Методы, встроенные в алгоритмы (отдельная библиотека SHAP*)

SHAP – значения показывают, насколько этот конкретный признак изменил наше предсказание (по сравнению с тем, как мы сделали бы это предсказание при некотором базовом значении этого признака).

Метод подходит
для большинства
моделей МЛ:




* Лучше изучить все [способы применения этого пакета](#)

Методы, встроенные в алгоритмы

L1-регуляризация — если коротко, это прибавление к лосс-функции суммы весов в модуле. Она добавляет «критическую величину» коэффициента как дополнение к функции потерь. Если веса ближе к нулю, они становятся равными нулю, тем самым отбираются только важные признаки

L2-регуляризация — аналогична L1-регуляризации, но вместо модуля используются квадраты весов



Преобразование признаков



Преобразование признаков

Преобразование признаков может проводиться с помощью:


- ✓ **PCA – principal component analysis**
(метода главных компонент)
- ✓ **LDA – linear discriminant analysis**
(линейного дискриминантного анализа)
- ✓ **NCA – neighbourhood components analysis**
(анализа компонентов соседств)
- ✓ **t-SNE – t-distributed stochastic neighbor embedding**
(стохастического вложения соседей с t-распределением)

PCA – principal component analysis

Метод главных компонент позволяет уменьшить размерность данных с помощью преобразования на основе линейной алгебры

Собственный вектор:

$$M\vec{x} = \lambda\vec{x}$$



Сингулярное разложение (SVD):

$$\begin{array}{c} A \\ n \times d \end{array} = \begin{array}{c} \hat{U} \\ n \times r \end{array} \begin{array}{c} \hat{\Sigma} \\ r \times r \end{array} \begin{array}{c} \hat{V}^T \\ r \times d \end{array}$$

$U \qquad \Sigma \qquad V^T$
 $n \times n \qquad n \times d \qquad d \times d$

PCA – principal component analysis

С математической точки зрения метод главных компонент представляет собой ортогональное линейное преобразование, которое отображает данные из исходного пространства признаков в новое пространство меньшей размерности.

- Первая ось новой системы координат строится таким образом, чтобы дисперсия данных вдоль неё была максимальна
- Вторая ось строится ортогонально первой так, чтобы дисперсия данных вдоль неё была максимальной из оставшихся возможных и т. д.

Первая ось называется первой главной компонентой, вторая — второй и т. д.

LDA – linear discriminant analysis

Линейный дискриминантный анализ – метод уменьшения размерности, используемый в качестве этапа предварительной обработки в приложениях машинного обучения и классификации.

Первый шаг – вычислить разделимость между разными классами, то есть расстояние между средними значениями разных классов, также называемое **межклассовой дисперсией**

$$S_b = \sum_{i=1}^g N_i (\bar{x}_i - \bar{x})(\bar{x}_i - \bar{x})^T$$

LDA – linear discriminant analysis

Второй шаг – вычислить расстояние между средним значением и выборкой каждого класса, которое называется **внутриклассовой дисперсией**

$$S_w = \sum_{i=1}^g (N_i - 1) S_i = \sum_{i=1}^g \sum_{j=1}^{N_i} (x_{i,j} - \bar{x}_i)(x_{i,j} - \bar{x}_i)^T$$

LDA – linear discriminant analysis



Третий шаг – построить пространство более низкой размерности, которое максимизирует дисперсию между классами и минимизирует дисперсию внутри класса.

P – проекция пространства нижней размерности

$$P_{lda} = \arg \max_P \frac{|P^T S_b P|}{|P^T S_w P|}$$

LDA: примеры


Отображение распределения в одномерное пространство:




LDA: примеры

Отображение картинок MNIST
в дву- и одномерное пространство

Двумерное представление:



Одномерное представление:



NCA – neighbourhood components analysis

Анализ компонентов соседств – алгоритм, использующий метод, аналогичный методу К-ближайших соседей, для нахождения пространства, в котором окрестности точек с одинаковыми метками более плотные, чем точки с разными метками

Используется расстояние Махаланобиса

$$d(x, y) = \|L(x - y)\|^2 = (x - y)^T Q (x - y) = (Ax - Ay)^T (Ax - Ay)$$

NCA – neighbourhood components analysis

Класс точки определяется взвешенным объединением классов всех остальных точек.

$$p_i = \sum_{j \in C_i} p_{ij}$$

$$p_{ii} = 0 \quad p_{ij} = \frac{\exp(-\|Ax_i - Ax_j\|^2)}{\sum_{k \neq i} \exp(-\|Ax_i - Ax_k\|^2)}$$


Приближение матрицы преобразования происходит градиентными итеративными методами

$$\frac{\partial f}{\partial A} = 2A \sum_i (p_i \sum_k p_{ik} x_{ik} x_{ik}^T - \sum_{j \in C_i} p_{ij} x_{ij} x_{ij}^T)$$


NCA: пример работы

Мы используем NCA, чтобы изучить эмбединги* и построить точки после преобразования. Затем мы берём вложение и находим ближайших соседей:

Исходные данные



Полученные эмбединги




* От англ. embedding – вложение

Сравнение LDA, PCA и NCA


PCA

Оси компонент
максимизируют
дисперсию




LDA

Оси компонент
максимизируют
разделение классов




NCA

Находит более
плотные группы
точек с одинаковыми
метками, а не разными




Сравнение LDA, PCA и NCA

Эксперименты, проведённые на различных данных с использованием разных алгоритмов, показывают, что в зависимости от датасета алгоритмы работают с разной эффективностью



t-SNE – t-distributed stochastic neighbor embedding

Стохастическое вложение соседей с t-распределением — метод нелинейного снижения размерности, хорошо подходящий для данных высокой размерности для визуализации в пространство низкой размерности (двух- или трёхмерное). T-SNE моделирует каждый объект высокой размерности точкой таким образом, что похожие объекты моделируются близко расположенными точками, а непохожие точки моделируются с большой вероятностью точками, далеко друг от друга отстоящими:



t-SNE – t-distributed stochastic neighbor embedding

Упрощённый алгоритм:

- 1 Оценка перплексии*

$$Perp(P_i) = 2^{H(P_i)} \quad H(P_i) = - \sum_j p_{j|i} \log_2 p_{j|i} \quad \text{где } H(P_i) \text{ — энтропия Шеннона}$$

- 2 Оценка сходства точек в пространстве

$$q_{ij} = \frac{(1 + \|y_i - y_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|y_k - y_l\|^2)^{-1}} \quad \text{где } y_{i/j} \text{ — пары точек в пространстве}$$

- 3 Вычисление градиента

$$\frac{\partial Cost}{\partial y_i} = 4 \sum_j (p_{ij} - q_{ij})(y_i - y_j)(1 + \|y_i - y_j\|^2)^{-1}$$

*Метрика оценки качества моделей, показывающая, насколько хорошо модель предсказывает детали тестовой коллекции

t-SNE – t-distributed stochastic neighbor embedding

Упрощённый алгоритм:

Data: набор данных $X = \{x_1, x_2, \dots, x_n\}$

Параметр функции потерь: перплексия **Perp**

Параметры оптимизации: количество итераций **T**, скорость обучения η , момент $\alpha(t)$

Result: представление данных $Y(T) = \{y_1, y_2, \dots, y_n\}$ (в 2D или 3D)

begin

1) вычислить попарное сходство p_{ji} с перплексией **Perp** (используя формулу 1)

2) установить $p_{ij} = (p_{ji} + p_{ij})/2n$

3) инициализировать $Y(0) = \{y_1, y_2, \dots, y_n\}$ точками нормального распределения (**mean=0, sd=1e-4**)

4) **for t = 1 to T do**

4.1) вычислить сходство точек в пространстве отображения q_{ij} (по формуле 2)

4.2) вычислить градиент $\delta \text{Cost} / \delta y$ (по формуле 3)

4.3) установить $Y(t) = Y(t-1) + \eta \delta \text{Cost} / \delta y + \alpha(t)(Y(t-1) - Y(t-2))$

end

end

Итоги



Итоги

- 1 С увеличением размерности пространства некоторые алгоритмы начинают работать хуже. Решить эту проблему помогают преобразование и отбор признаков
- 2 Методы отбора признаков позволяют упростить модели, сократить время тренировки, уменьшить влияние проклятия размерности, сократить переобучение, отфильтровать шумные признаки
- 3 Методы отбора признаков обычно делят на фильтры, обёртки, встроенные в алгоритмы
- 4 Преобразование признаков может проводиться с помощью метода главных компонент, линейного дискриминантного анализа, анализа компонент соседств и стохастического вложения соседей с t-распределением



Генерация переменных и feature selection

Алексей Кузьмин
Директор разработки в «ДомКлик»

