


Линейный классификатор и логистическая регрессия

Алексей Кузьмин
Директор разработки в «Домклик»



Алексей Кузьмин

О спикере:

- директор разработки в Домклик
- руководил направлением работы с данными и машинного обучения
- под управлением ~600 человек
- экс-сотрудник АBBYY, где занимался распознаванием языков со сложной письменностью
- выпускник мехмата МГУ



План занятия

- 1 Линейные модели
- 2 Задача классификации
- 3 Логистическая регрессия
- 4 SVM (Support vector machines)


Линейные модели



Линейные модели предполагают,
что определяемый критерий линейно
зависит от признаков, описывающих
объект или процесс


Линейные модели

Регрессия



x — (единственный) признак
 y — таргет

Классификация



$ax_1 + bx_2 + c > 0$
Класс 1

$ax_1 + bx_2 + c = 0$
Разделяющая прямая

x_1, x_2 — признаки

Линейные модели

Плюсы:

- 1 **Скорость и простота** получения модели
- 2 **Интерпретируемость модели.** Линейная модель прозрачна и понятна для аналитика. По полученным коэффициентам регрессии можно судить, как тот или иной фактор влияет на результат, сделать на этой основе дополнительные полезные выводы
- 3 **Широкая применимость.** Множество реальных процессов в экономике и бизнесе можно с достаточной точностью описать линейными моделями
- 4 **Изученность подхода.** Для линейной регрессии известны типичные проблемы (например, мультиколлинеарность) и их решения, разработаны и реализованы тесты оценки статической значимости получаемых моделей

Линейные модели

Минусы:

- 1 Не могут уловить сложные зависимости в данных
- 2 Есть проблемы с мультиколлинеарностью

Виды регрессий

Полиномиальная регрессия:

$$f(X) = \sum_{i=1, j=1}^{n, m} w_i x_i^j + b$$

Логарифмическая регрессия:

$$f(X) = \sum_{i=1, j=1}^{n, m} w_i \ln(x_i) + b$$

Экспоненциальная регрессия:

$$f(x) = \sum e^{wx} + b$$

Гиперболическая регрессия:

$$f(x) = \sum w \cdot 1/x + b$$



Выбор зависит от вида данных.

В идеале нужно попробовать несколько


Задача классификации

Линейная разделимость данных


Классификация — задача предсказания ответа из **конечного** множества вариантов

Линейный классификатор решает задачу разделения признакового пространства на две части, в каждой из которых находится свой класс:

Линейное
разделение



Нелинейное
разделение



Линейная разделимость данных

Отступ — расстояние от разделяющей гиперповерхности до объекта:

$$M(\vec{x}_i) = y_i \vec{w}^T \vec{x}_i$$

→ Отступ можно понимать как степень погружённости объекта в свой класс

Линейная разделимость данных

X_3


отступ большой и положительный, объект далеко от разделяющей гиперплоскости и классифицируется уверенно

X_1

отступ большой и отрицательный, объект далеко от разделяющей гиперплоскости и скорее всего является аномалией

X_2 И X_4

отступ малый, объект близко к разделяющей гиперплоскости, знак отступа определяет, правильно ли объект классифицирован




Логистическая регрессия

Логистическая регрессия

Логистическая регрессия – линейный классификатор, позволяющий **оценивать вероятности** принадлежности объектов классам:


$$L = a_0 + a_1X_1 + a_2X_2 + \dots + a_nX_n$$

$$p = \frac{1}{1 + e^{-L}}$$



Линейная регрессия


- 1 Регрессия
- 2 Предсказать значение
- 3 $y = aX + b$




VS

Логистическая регрессия

- 1 Классификация
- 2 Предсказать вероятность класса
- 3 $y = \sigma(aX + b)$






Функция потерь

Бинарная кросс-энтропия (binary cross-entropy loss):

$$L = -\frac{1}{m} \sum_{i=1}^m (y_i \cdot \log(\hat{y}_i) + (1 - y_i) \cdot \log(1 - \hat{y}_i))$$



Функция потерь – дифференцируемая функция

Дифференцирование нужно, чтобы найти оптимальные параметры, минимизирующие ошибку L .

Метрики качества (точность, полнота, F-мера, и т.д.) – недифференцируемые функции. Не могут быть использованы для обучения

Полиномиальная логистическая регрессия

? Что делать, если надо предсказать больше двух классов?

→ Вероятность принадлежности к классу y вычисляют по формуле:

$$p(y|\mathbf{x}; \mathbf{w}) = \frac{\exp(\mathbf{w}_y^T \mathbf{x})}{\sum_{z \in Y} \exp(\mathbf{w}_z^T \mathbf{x})} = \text{SoftMax}_{y \in Y}(\mathbf{w}_y^T \mathbf{x})$$

SoftMax — обобщение логистической функции для многоклассового случая


SVM (Support vector machines)

Множество гиперплоскостей

SVM (метод опорных векторов, support vector machine) находит оптимальную разделяющую поверхность.

Максимизирует зазор между классами

Граница:
 $ax + by - c = 0$



Максимальный зазор

$\mathbf{X}$ — sample

x_1 , x_2 — признаки

$\mathbf{W}$ — нормаль к разделяющей гиперплоскости


y_i — класс sample i $\{+1, -1\}$, (не $\{0, 1\}$)

Классификатор: $f(x_i) = \text{sign}(w^T x + b)$

Зазор для точки $x = y \frac{w^T x + b}{\|w\|}$

Зазор всего датасета — минимум зазора для всех точек

! **Цель** — найти гиперплоскость, задаваемую вектором нормали w , чтобы зазор r был максимальным



Формула

Итого получаем задачу оптимизации:

Найти такие веса $\mathbf{w}$ и b , чтобы:

- 1 объекты классов лежали как можно дальше от разделяющей гиперплоскости
- 2 для всех $\{(\mathbf{x}_i, y_i)\}$ $\mathbf{w}^T \mathbf{x}_i + b \geq 1$ если $y_i=1$; $\mathbf{w}^T \mathbf{x}_i + b \leq -1$ если $y_i=-1$

Перепишем в более понятном виде:

Найти такие веса $\mathbf{w}$ и b , чтобы $\Phi(\mathbf{w})=0.5\mathbf{w}^T\mathbf{w}$ было максимально
и для всех $\{(\mathbf{x}_i, y_i)\}$: $y_i (\mathbf{w}^T \mathbf{x}_i + b \geq 1)$

→
Решаемая задача
математической
оптимизации
(множители Лагранжа)

Логистическая регрессия

vs


Машина опорных векторов

- 1 Классификация
- 2 Предсказать вероятность
положительного класса $[0,1]$
- 3 Минимизировать кросс-энтропию
- 4 Хуже работает с выбросами —
выбросы могут сильно повлиять
на обучаемую функцию
- 5 Требуется нормализации данных
для лучшего выбора весов

- 1 Классификация
- 2 Предсказать метки классов
 $\{+1, -1\}$
- 3 Максимизировать зазор
- 4 Лучше работает с выбросами —
выбросы не влияют на опорные векторы
и разделяющую гиперплоскость
- 5 Требуется нормализации данных
для более корректного подсчёта
расстояний между векторами


SVM для линейно неразделимых классов

Линейно разделимые датасеты
хорошо классифицируются:




SVM для линейно неразделимых классов

Но что делать, если они линейно
неразделимы?



SVM для линейно неразделимых классов

Можно попробовать отобразить
данные в пространство более
высокой размерности:



The kernel trick



→ SVM зависит от скалярного произведения:

$$K(x_i, x_j) = x_i^T x_j$$

→ Если каждая точка отображается в пространство более высокой размерности при помощи $\Phi: x \rightarrow \phi(x)$, то скалярное произведение:

$$K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$$

3 Функция ядра — это функция, соответствующая скалярному произведению в пространстве более высокой размерности



Kernels (ядра)

Линейное:

Может быть полезно для классификации текстов (большая размерность данных)

$$k(\mathbf{x}, \mathbf{x}') = (\mathbf{x} \cdot \mathbf{x}')$$

Полиномиальное:

$$k(\mathbf{x}, \mathbf{x}') = (\mathbf{x} \cdot \mathbf{x}')^d$$

Полиномиальное со смещением:

Полиномиальные ядра лучше использовать, если данные нормализованы

$$k(\mathbf{x}, \mathbf{x}') = (\mathbf{x} \cdot \mathbf{x}' + 1)^d$$

Kernels (ядра)

**Радиальная
базисная функция:**

$$k(\mathbf{x}, \mathbf{x}') = \exp(-\gamma \|\mathbf{x} - \mathbf{x}'\|^2), \text{ для } \gamma > 0$$

**Радиальная базисная
функция Гаусса:**

Используют по умолчанию,
если нет дополнительной информации
о данных

$$k(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\sigma^2}\right)$$

ИТОГИ

Итоги

- Линейные модели предполагают, что определяемый критерий линейно зависит от признаков, описывающих объект или процесс
- Линейный классификатор решает задачу разделения признакового пространства на две части, в каждой из которых находится свой класс
- Логистическая регрессия — линейный классификатор, позволяющий оценивать вероятности принадлежности объектов классам
- SVM (Support vector machine) находит оптимальную разделяющую поверхность
- Функция ядра — это функция, соответствующая скалярному произведению в пространстве более высокой размерности

Линейный классификатор и логистическая регрессия

Алексей Кузьмин
Директор разработки в «Домклик»

