


Ансамблирование моделей

Алексей Кузьмин
Директор разработки в Домклик



Алексей Кузьмин

О спикере:

- Директор разработки в Домклик
- Руководил направлением работы с данными и машинного обучения
- Под управлением ~ 600 человек
- Экс-сотрудник АBBYY, где занимался распознаванием языков со сложной письменностью
- Выпускник мехмата МГУ



Цели занятия

- Изучить основные подходы к ансамблированию моделей в машинном обучении
- Понять принципы повышения качества предсказаний с помощью ансамблей
- Рассмотреть особенности методов бэггинга, бустинга, стекинга и случайного леса
- Выяснить, как ансамблирование связано со смещением, разбросом и обобщающей способностью модели

План занятия

- 1 Введение
- 2 Ансамбли
- 3 Используемые концепции построения

Введение

Фрэнсис Гальтон «Мудрость толпы»

Фрэнсис Гальтон в 1906 году посетил рынок, где проводилась лотерея для крестьян.

Около 800 человек пытались угадать вес быка, который стоял перед ними. Ни один крестьянин не угадал точный вес, но если посчитать среднее от их предсказаний, то получим 1 197 фунтов. Животное весило 1 198 фунтов.

Эту идею уменьшения ошибки применили и в машинном обучении

Теорема Кондорсе о жюри присяжных

Если каждый член жюри присяжных имеет независимое мнение и вероятность правильного решения члена жюри больше 0,5, то тогда вероятность правильного решения присяжных в целом возрастает с увеличением количества членов жюри и стремится к единице.

Если же вероятность быть правым у каждого из членов жюри меньше 0,5, то вероятность принятия правильного решения присяжными в целом монотонно уменьшается и стремится к нулю с увеличением количества присяжных.

N — количество присяжных

p — вероятность правильного решения присяжного

μ — вероятность правильного решения всего жюри

m — минимальное большинство членов жюри, $m = \text{floor}(N/2) + 1$

C_N^i — число сочетаний из N по i

$$\mu = \sum_{i=m}^N C_N^i p^i (1-p)^{N-i}$$

Если $p > 0.5$, то $\mu > p$


Если $N > \infty$, то $\mu \rightarrow 1$

Ансамбли

Ансамбли алгоритмов (стекинг)

Основная идея:


- 1 Использовать множество алгоритмов. Их называют базовыми/слабыми
- 2 Объединить их ответы метамоделью или более простым методом



Концепция разброса-смещения

Разброс (variance)


Дисперсию ответов алгоритмов характеризует разнообразие алгоритмов из-за случайности обучающей выборки, в том числе шума, и стохастической природы настройки




Концепция разброса-смещения

Смещение (bias)

Математическое ожидание разности между истинным ответом и выданным алгоритмом, характеризует способность модели алгоритмов настраиваться на целевую зависимость



Концепции недообучения и переобучения



- Недообученные модели в силу простоты не могут описать целевую зависимость и имеют большое смещение (bias)
- Переобученные модели слишком хорошо запомнили обучающую выборку и имеют большой разброс (variance)

Концепции построения

Методы ансамблирования

- **Простое голосование** — набор различных моделей, в котором голосует каждая и решает большинство
- **Взвешенное голосование** — набор различных моделей, в котором голосует каждая с заранее определённым весом и решает большинство
- **Смесь экспертов** — набор различных моделей, в котором голосует каждая с весом, зависящем от данных, по которым требуется сделать предсказание

Усреднение

Для регрессии:


- усреднение
- медиана
- усреднение с весами

Для классификации:

- голосование
- голосование с весами



Бутстреп (Bootstrap)

Исходная выборка



Статистика по выборке

Бутстреп-выборки



Статистика
по бутстреп-выборкам

Статистика 1

Статистика 2

Статистика 3



Бутстреп-распределение

Бэггинг (Bagging)

Bagging – bootstrap aggregating

Использует однородные базовые алгоритмы и параллельно обучает на случайном подмножестве выборки.

При объединении результатов мы складываем случайные величины. Поэтому для получения несмещённого результата нам нужны модели с малым смещением.

Большой разброс при объединении уменьшится в соответствии с ЦПТ



Бэггинг (Bagging)

```
From sklearn.ensemble import BaggingRegressor
```

- **base estimator** object or None — модель регрессии из scikit-learn (по умолчанию деревья решений)
- **n_estimators** — количество моделей
- **max_samples** int or float, optional (default = 1,0) — количество семплов для обучения
- **max features** int or float, optional (default = 1,0) — количество признаков для обучения

Случайные подпространства

Предположим, что в наборе данных есть один очень сильный признак.

При использовании бэггинга бóльшая часть деревьев будет использовать этот признак в качестве первого, по которому производится деление. В результате образуется ансамбль похожих деревьев, которые сильно коррелированы.

Усреднение высокоррелированных величин не приводит к значительному уменьшению дисперсии (что является целью бэггинга). Случайно исключая признаки из каждого расщепления, Random forest «декоррелирует» деревья, так что процесс усреднения может уменьшить дисперсию результирующей модели

Random Forest (Случайный лес)

Бэггинг + случайные подпространства = случайный лес

Случайный лес — вариация бэггинга над деревьями, дающая даже лучшие результаты.


Как и в бэггинге, мы создаём ансамбль деревьев решений, используя выборки из обучающего набора. Однако при построении каждого дерева каждый раз, когда производится расщепление, признак выбирается из случайной выборки размера m всех признаков.

Новая случайная выборка признаков формируется для каждого отдельного дерева в каждом отдельном расщеплении.

Для классификации m обычно выбирается как квадратный корень из p .

Для регрессии m обычно выбирается где-то между $p/3$ и p

Random Forest (Случайный лес)




Random Forest (Случайный лес)

```
From sklearn.ensemble import DecisionTreeRegressor
```

- **criterion** — метод оценки ошибки (MSE по умолчанию)
- **splitter str** — метод разделения «better» или «random»
- **n_estimators** — количество моделей
- **max depth** — максимальная глубина деревьев
- **max_samples** int or float, optional (default=1.0) — количество семплов для обучения
- **max features** int or float, optional (default=1.0) — количество признаков для обучения


Ансамбли строят лучшую разделяющую границу

Дерево решений



Граница — прямоугольники.
Точность — 80%


Случайный лес



Граница — гладкая кривая.
Точность — 92%


БУСТИНГ

Бустинг (англ. boosting — улучшение) — это процедура последовательного построения композиции однородных базовых алгоритмов, когда каждый следующий алгоритм стремится компенсировать недостатки композиции всех предыдущих



БУСТИНГ


AdaBoosting — для каждого следующего алгоритма увеличивается вес ошибки для неверно полученных результатов



БУСТИНГ


Обучение происходит последовательно.

Так как очередной алгоритм исправляет предыдущий, то нам не подходят алгоритмы с большим разбросом



БУСТИНГ

Градиентный бустинг сводит задачу к градиентному спуску и на каждой итерации подгоняет очередной базовый алгоритм в соответствии с антиградиентом ошибки текущей модели ансамбля



XGBoost. Простой пример

Первое дерево может давать много ошибок

Клип	Есть 1 000 000?	Что ответило дерево
1	Нет	Нет
2	Нет	Да
3	Нет	Нет
4	Да	Да
5	Нет	Да
6	Нет	Нет
7	Да	Нет
8	Нет	Нет
9	Нет	Нет
10	Нет	Да
11	Нет	Да
12	Да	Да
...	...	...
10 000	Нет	Нет


XGBoost. Простой пример

Учим второе дерево исправлять ошибки предшественника

Клип	Есть 1 000 000?	Что ответило дерево
1	Нет	Нет
2	Нет	Да
3	Нет	Нет
4	Да	Да
5	Нет	Да
6	Нет	Нет
7	Да	Нет
8	Нет	Нет
9	Нет	Нет
10	Нет	Да
11	Нет	Да
12	Да	Да
...	...	...
10 000	Нет	Нет

Дерево, обрати внимание

Понял, принял



Стекинг

Использует разнородные базовые алгоритмы, обучает их параллельно. Для объединения результатов используется так называемая метамодель (модель второго уровня), которая предсказывает конечный результат.


Можно построить и более двух уровней стекинга.

Два основных подхода к обучению стекинга:


1 Блендинг

2 Стекинг

Блендинг



Стекинг



Итоги

Итоги

- Ансамблирование — техника для улучшения качества предсказаний, при которой несколько моделей обучаются отдельно, а затем их предсказания усредняются
- Методы ансамблирования: простое голосование, взвешенное голосование, смесь экспертов, бустинг, бэггинг, стекинг
- Случайный лес — вариация бэггинга над деревьями, дающая лучшие результаты
- Ансамбли позволяют построить лучшую разделяющую границу, чем деревья решений

Дополнительная информация

Рекомендации для ознакомления

-  Ансамбли в машинном обучении
-  Ансамблевые методы: бэггинг, бустинг и стекинг

Ансамблирование моделей

Алексей Кузьмин
Директор разработки в Домклик

