


Повышение качества процесса моделирования

Алексей Кузьмин
Директор разработки в Домклик



Алексей Кузьмин

О спикере:

- директор разработки в Домклик
- исполнительный директор по исследованию данных в Домклик
- руководил направлением работы с данными и машинным обучением
- под управлением ~ 600 человек
- работал в АВВУУ, где занимался распознаванием языков со сложной письменностью
- выпускник мехмата МГУ



Цели занятия

- Узнать способы повышения качества моделирования
- Понять, как количество, качество и обработка данных влияют на результат модели
- Изучить методы работы с алгоритмом при недообучении и переобучении
- Рассмотреть подходы к подбору гиперпараметров
- Выяснить разницу между обычными параметрами и гиперпараметрами модели
- Разобраться, когда помогает переосмысление подхода

План занятия

- 1 Способы повышения качества процесса обучения
- 2 Работа с алгоритмом или моделью

Способы повышения качества процесса моделирования

Улучшение качества модели

- 1 Работа с данными
- 2 Работа с алгоритмом
- 3 Переосмысление подхода

Работа с данными

- 1 Получить больше данных: обучать модель на большем количестве данных
- 2 Улучшить качества данных
- 3 Обработать данные
- 4 Придумать больше данных

Работа с алгоритмом

Необходимо определить, правильно ли выбран алгоритм, точно ли он работает оптимально.

Для этого используются:

- 1 Усложнение модели или уменьшение регуляризации при недообучении: выбор более сложной модели или настройка гиперпараметров
- 2 Упрощение или регуляризация при переобучении: выбор более простой модели или настройка гиперпараметров

Переосмысление проблемы

Чтобы понять, правильно ли выбран подход, следует:

- 1 Прогнозировать сумму продаж в неделю, а не в день
- 2 Построить ансамбль:
 - разделить данные на категории и работать с каждой категорией по-разному
 - выделить подзадачи/подмодели в рамках текущего подхода: прогнозировать сумму продаж в неделю, далее разбивать её по дням недели

Увеличение количества данных

- 1 Накопить больше данных
- 2 Разметить больше данных
- 3 Найти дополнительные источники данных
- 4 Сгенерировать новые данные из исходных (аугментация).
Для изображений это поворот, работа с цветом и т.д.

Улучшение качества данных

1 Изменить процесс сбора данных:

- качество сенсоров
- уменьшение сжатия данных
- качество фото- или видеосъемки

2 Проблемы с данными могут быть на уровне схемы БД:

- неуникальные значения
- неверные значения данных (возраст)
- дубликаты

Обработка данных

- 1 Сгенерировать новые гипотезы или переменные, помогающие лучше решить задачу
- 2 Удалить часть ошибочных данных
- 3 Удалить часть периода данных:
 - выбросы
 - нетипичный период: например, время локдауна из следующих или предыдущих годов

Работа с алгоритмом или моделью

Модель для задачи обучения с учителем

Модель представляем как функцию с параметрами:

$$y = f(\theta) + \varepsilon$$

где:

- θ — параметры алгоритма
- ε — неустраняемая ошибка

Модель для задачи обучения с учителем

Параметры модели θ можно разделить на обучаемые w (обычные параметры) и необучаемые g (гиперпараметры):


$$f(g, w)$$

Параметры модели задают семейство функций, которые она может реализовать

Обычные параметры модели

Обычные параметры мы получаем в процессе обучения.

Подбор обычных параметров производится через минимизацию функции потерь L



Как подбирать гиперпараметры


- 1 **Ручной выбор** — на основе своей экспертной оценки вы выбираете гиперпараметры модели
- 2 **Поиск по сетке** — перебор всех вариантов
- 3 **Случайный поиск** — проверяются случайные семплы из пространства гиперпараметров

Как подбирать гиперпараметры

- 4 **Байесовский подход** — это модификация случайного поиска. В его основе лежит идея о том, что для выбора лучшей области пространства гиперпараметров следует учитывать историю уже рассмотренных точек, в которых были обучены модели и получены значения целевой функции
- 5 **Генетические алгоритмы** — применяются эволюционные алгоритмы с мутациями и скрещиванием: градиентные методы и множество других

Поиск по сетке – Grid Search

Полный перебор по заданному вручную подмножеству пространства гиперпараметров



Источник изображения

Поиск по сетке — Grid Search

Минусы:


- Долго: количество комбинаций $N_1 \times N_2 \times N_3 \dots \times N_i$, где N_i — количество возможных значений i -го параметра
- Не оптимальное решение, если неправильно задать пространство гиперпараметров

Плюсы:

- Просто

Случайный поиск — Randomized Search

Многократное обучение на случайном семплированном наборе гиперпараметров



Источник изображения

Случайный поиск — Randomized Search

Минусы:


- Не гарантируется лучшее решение

Плюсы:

- Просто
- Обычно быстрее находит хорошее решение, чем Grid Search

Байесовская оптимизация

Основная идея алгоритма — на каждой итерации подбора находится компромисс между исследованием регионов с самыми удачными из найденных комбинаций гиперпараметров и исследованием регионов с большой неопределённостью, где могут находиться ещё более удачные комбинации



[Подробнее](#)

[Источник изображения](#)

Байесовская оптимизация

Для этого алгоритм строит вероятностную модель функции отображения значений гиперпараметров на целевую функцию.

Значения гиперпараметров в текущей итерации выбираются с учётом результатов на предыдущем шаге.

Это позволяет во многих случаях найти лучшие значения параметров модели за меньшее количество времени

Байесовская оптимизация

Минусы:


- Сложно реализовать, но есть готовые пакеты

Плюсы:

- Хорошо находит оптимум

Генетические алгоритмы оптимизации

Эволюционная оптимизация гиперпараметров следует процессу, навеянному биологической концепцией эволюции



Генетические алгоритмы оптимизации

Минусы:

- Сложно и долго

Плюсы:

- Глобальная оптимизация

ИТОГИ

Итоги

- Улучшить качество модели можно посредством работы с данными, работы с алгоритмом и путём переосмысления подхода
- Работать с данными можно следующими способами: получить больше данных (обучать модель на большем количестве данных), улучшить качество данных, обработать данные, придумать больше данных
- При работе с алгоритмом могут использоваться усложнение модели или уменьшение регуляризации при недообучении, упрощение и/или регуляризация при переобучении
- Понять, правильно ли выбран подход, можно через прогнозирование суммы продаж в неделю или построение ансамбля
- При работе с моделью её параметры можно разделить на обычные (обучаемые) и гиперпараметры (необучаемые)
- Подбор обычных параметров производится через минимизацию функции потерь L , подбор гиперпараметров — через ручной выбор, поиск по сетке, случайный поиск, байесовскую оптимизацию или генетические алгоритмы

Повышение качества процесса моделирования

Алексей Кузьмин
Директор разработки в Домклик

