


Работа со сложными данными

Алексей Кузьмин
Директор разработки в Домклик



Алексей Кузьмин

О спикере:

- директор разработки в Домклик
- руководил направлением работы с данными и машинным обучением
- под управлением ~ 600 человек
- работал в АBBYY, где занимался распознаванием языков со сложной письменностью
- выпускник мехмата МГУ



Цели занятия

- Узнать, какие задачи возникают при работе со сложными данными
- Изучить основные методы представления и предобработки текстов
- Понять, как измеряется близость текстов, слов и объектов
- Разобраться в подходах к работе с изображениями и в основах наивного байесовского классификатора

План занятия

- 1 Работа с текстом
- 2 Методы предобработки текстов
- 3 Меры близости
- 4 Работа с изображениями
- 5 Наивный байесовский классификатор

Работа с текстом

Основные задачи

Машинный
перевод

Чат-боты

Генерация текстов

Проверка
правописания

Классификация/кластеризация текстов:

- фильтрация спама
- по тональности
- по теме или жанру

Извлечение информации:

- фактов и событий
- именованных сущностей

Проблемы работы с текстом

Компьютеры работают с числовыми данными.

Наша задача — преобразовать текст в формат чисел.

Это можно сделать разными способами:

- частота встречаемости слова, типа, лексемы
- мешок слов (Bag-of-words)
- эмбединги

Проблемы работы с текстом: задача

Необходимо получить ответ на вопрос: сколько слов в предложении «На дворе трава, на траве дрова, не руби дрова на траве двора»

Проблемы работы с текстом: решение

Необходимо получить ответ на вопрос: сколько слов в предложении «На дворе трава, на траве дрова, не руби дрова на траве двора».

Ответ:

- 12 токенов¹: На, дворе, трава, на, траве, дрова, не, руби, дрова, на, траве, двора
- 8–9 типов²: Н/на, дворе, трава, траве, дрова, не, руби, двора
- 6 лексем³: на, не, двор, трава, дрова, рубить

¹ Токен — тип и его позиция в тексте

² Тип — уникальное слово из текста

³ Лексема — слово как абстрактная единица морфологического анализа: словарь/словарю — одна лексема

Методы предобработки текстов

Counter (частота встречаемости слова)

Компьютеры работают с числами. Давайте посмотрим, как перевести слова в числа и учесть слова в документах.

1 Слово → число. Мама — 1, мыть — 2, рама — 3, ...

Мама мыла раму → [1, 2, 3]

Counter (частота встречаемости слова)

Компьютеры работают с числами. Давайте посмотрим, как перевести слова в числа и учесть слова в документах.

2

Слово → бинарный вектор

	Слово 1	Слово 2	...	Слово N
Документ 1	1	0		2
Документ 2	0	0		0
...				
Документ K	0	1		0

TF-IDF

TF (term frequency – частота слова) – отношение числа вхождений некоторого слова к общему числу слов в документе. Оценивается важность слова в пределах отдельного документа

IDF (inverse document frequency – обратная частота документа) – инверсия частоты, с которой некоторое слово встречается в документах коллекции. Для каждого уникального слова в пределах конкретной коллекции документов существует только одно значение IDF

$$\text{tfidf}(t, d, D) = \text{tf}(t, d) \times \text{idf}(t, D)$$

	Документ 1	Документ 2	...	Документ n
Условия 1	12	2		й
Условия 2	0	1		0
...				
Условия n	0	6		3

TF-IDF

$$tf(t, d) = \frac{n_t}{\sum_k n_k}$$

$$idf(t, D) = \ln \left(\frac{|D|}{|\{d \in D : t \in d\}|} \right)$$

n_t — число вхождений слова t в документ, а в знаменателе — общее число слов в этом документе.

$|D|$ — число документов в коллекции.

$$|\{d_i \in D : t \in d_i\}|$$

— число документов из коллекции D , в которых встречается t , когда

$$n_t \neq 0$$

Выбор основания логарифма в формуле не имеет значения, поскольку изменение основания приводит к изменению веса каждого слова на постоянный множитель, что не влияет на соотношение весов

TF-IDF

Большой вес в TF-IDF получают слова с высокой частотой в пределах конкретного документа и с низкой частотой употреблений в других документах.

Таким образом, мера TF-IDF является произведением двух сомножителей:

$$tfidf(t, d, D) = tf(t, d) \times idf(t, D)$$

Способы векторного представления слов. Мешок слов (Bag-of-words) и эмбединги

Традиционные методы — мешок слов	Эмбединг слов
• One hot encoding • Каждое слово в словаре представляется одной единицей в большом словаре • Информация в контексте не используется Если в словаре 10 000 слов и слово Hello — 4-е слово в словаре, то оно представляется вектором 000100...000	• Представляет каждое слово как точку в пространстве с фиксированной размерностью • Unsupervised строится на основе большого корпуса текста Слово Hello может быть представлено: [0,4, -0,11, 0,55, 0,3 ... 0,1, 0,02]

Способы векторного представления слов Word2vec


Word2vec — группа алгоритмов, предназначенных для получения вещественных векторных представлений слов в пространстве с невысокой фиксированной размерностью (word embedding):

- ВХОД — коллекция текстов
- ВЫХОД — векторные представления слов

Как правило, в векторном представлении семантически близкие слова оказываются рядом.

Идея: слова со схожими значениями разделяют схожий контекст

Векторное представление слов



$$\text{vector[Queen]} = \text{vector[King]} - \text{vector[Man]} + \text{vector[Woman]}$$


- Полученные векторы-слова отражают различные грамматические и семантические концепции
- Это также объясняет, почему эти векторы могут использоваться как функции в традиционных задачах НЛП: маркировка речевой главы, идентификация имени существительного

Эмбединги из языковых моделей: BERT

BERT — это нейронная сеть от Google, показавшая с большим отрывом state-of-the-art результаты на целом ряде задач. С помощью BERT можно создавать программы с ИИ для обработки естественного языка: отвечать на вопросы, заданные в произвольной форме, создавать чат-боты, автоматические переводчики, анализировать текст и так далее.

BERT предварительно обучен двум задачам НЛП:

- masked language modelling — способ предсказания слов, которые изначально были намеренно скрыты в предложении
- предсказание следующего предложения




Эмбеддинги из языковых моделей: ELMo

Эмбеддинги ELMo (Embeddings from Language Model) являются контекстно-зависимыми.

Они создают разные представления для слов, которые имеют одинаковое написание, но имеют разные значения (омонимы): bank, river bank и bank balance.

Его создали исследователи из института искусственного интеллекта Аллена и Вашингтонского университета



Мера близости

Меры близости векторов/точек

Коэффициент сходства – безразмерный показатель сходства сравниваемых объектов, который нужен, чтобы сравнивать вектора.

Расстояние и норма Минковского

$$\rho_p(x, y) = \left(\sum_{i=1}^d |x_i - y_i|^p \right)^{1/p}$$

$$\|x\|_p = \left(\sum_i |x_i|^p \right)^{\frac{1}{p}}$$

Расстояние Минковского порядка p между двумя точками определяется, как:

$p = 2$ – евклидово расстояние

$p = 1$ – манхэттенское расстояние

$p = \infty$ – расстояние Чебышёва (максимальное расстояние между двумя признаками)

Манхэттенское расстояние

$$\rho_1(x, y) = \|x - y\|_1 = \sum_{i=1}^n |x_i - y_i|$$

Евклидово расстояние

$$\rho_2(x, y) = \|x - y\|_2 = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Расстояние Чебышёва

$$\rho_\infty(x, y) = \max_{i=1, \dots, d} |x_i - y_i|.$$

$$\|x\|_1 = \sum_{i=1}^n |x_i|$$

$$\|x\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2}$$

Мера семантической близости

Расстояние Хэмминга — число позиций, в которых соответствующие символы двух слов одинаковой длины различны

1	1	1	1	0	0	0	0
1	0	1	1	1	0	0	1

Мера семантической близости

Коэффициент Жаккара — это мера, основанная на использовании информации о множестве общих символов. Она равна отношению пересечения двух множеств к их объединению

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|}$$

Работа с изображениями

Работа с изображениями


Датасет MNIST —
классификация
изображений цифр.

Задача: выберите хорошее
признаковое описание
изображения

$X = (x_1, \dots, x_n)$
для дальнейшего
использования алгоритмов



MNIST dataset




Цифра — матрица 32x32
со значениями яркости

Работа с изображениями

Прямой способ — преобразовать матрицу интенсивностей в вектор. У него есть недостатки:

- слишком большое число признаков — для картинки 28×28 получается 784 признака
- близкие в признаковом пространстве объекты не соответствуют одному классу





Работа с изображениями

Метод уменьшения размерности (PCA):

- количество признаков уменьшается: с 784 до нескольких десятков
- объекты одного класса образуют компактные области в признаковом пространстве

Работа с изображениями

Метод уменьшения размерности (РСА):



Наивный байесовский классификатор

Наивный байесовский классификатор

Наивный байесовский классификатор – простой вероятностный классификатор, основанный на применении теоремы Байеса со строгими (наивными) предположениями о независимости.

Формула Байеса:

$$P(A|B) = \frac{P(B|A) * P(A)}{P(B)}, \text{ где}$$

$P(A)$ – априорная вероятность гипотезы A

$P(A|B)$ – вероятность гипотезы A при наступлении события B (апостериорная вероятность)

$P(B|A)$ – вероятность наступления события B при истинности гипотезы A

$P(B)$ – полная вероятность наступления события B

Наивный байесовский классификатор

Плюсы:

- Алгоритм быстро предсказывает класс тестового набора данных
- Хорошо справляется с многоклассовым прогнозированием
- Производительность наивного байесовского классификатора лучше, чем у других простых алгоритмов
- Вам требуется меньше обучающих данных
- Хорошо работает с категориальными признаками (по сравнению с числовыми).
Для числовых признаков предполагается нормальное распределение, что может быть серьёзным допущением в точности нашего алгоритма

Наивный байесовский классификатор

Минусы:

- Если переменная имеет в тестовом наборе данных категорию, которая не наблюдалась в обучающем, то модель присвоит 0 (нулевую вероятность) и не сможет сделать предсказание. Это часто называют нулевой частотой. Чтобы решить эту проблему, мы можем использовать технику сглаживания. Один из самых простых методов сглаживания называется [оценкой Лапласа](#)
- Значения спрогнозированных вероятностей не всегда точные
- Ограничение этого алгоритма — предположение о независимости признаков. Однако в реальных задачах полностью независимые признаки встречаются крайне редко

Наивный байесовский классификатор

Достоинство наивного байесовского классификатора — малое количество данных, необходимых для обучения, оценки параметров и классификации

$$\arg \max \left[P(Q_k) \prod_{i=1}^n P(x_i | Q_k) \right]$$

$$P(Q_k) = \frac{\text{число документов класса } Q_k}{\text{общее количество документов}}$$

$$P(x_i | Q_k) = \frac{\alpha + N_{ik}}{\alpha M + N_k} \quad \text{вхождение слова } x_i \text{ в документ класса } Q_k$$

$$N_k \text{ — количество слов, входящих в документ класса } Q_k$$

$$M \text{ — количество слов из обучающей выборки}$$

$$N_{ik} \text{ — количество вхождений слова } x_i \text{ в документ класса } Q_k$$

$$\alpha \text{ — параметр для сглаживания}$$

Наивный байесовский классификатор

Спам:

- «Путёвки по низкой цене»
- «Акция! Купи шоколадку и получи телефон в подарок»

Не спам:

- «Завтра состоится собрание»
- «Купи килограмм яблок и шоколадку»

Задание. Определить, к какой категории отнести следующее письмо: «В магазине гора яблок. Купи семь килограмм и шоколадку»

Слова из обучающей выборки	Слово	Кол-во вхождений в «Спам»	Кол-во вхождений в «Не спам»	$P(x_i \text{Спам})$	$P(x_i \text{Не спам})$
	Путевки	1	0		
	Низкой	1	0		
	Цене	1	0		
	Акция	1	0		
	Купи	1	1	$\frac{1+1}{14+9}$	$\frac{1+1}{14+7}$
	Шоколадку	1	1	$\frac{1+1}{14+9}$	$\frac{1+1}{14+7}$
	Получи	1	0		
	Телефон	1	0		
	Подарок	1	0		
	Завтра	0	1		
	Состоится	0	1		
	Собрание	0	1		
	Килограмм	0	1	$\frac{1+0}{14+9}$	$\frac{1+1}{14+7}$
	Яблок	0	1	$\frac{1+0}{14+9}$	$\frac{1+1}{14+7}$
	Магазине	0	0	$\frac{1+0}{14+9}$	$\frac{1+0}{14+7}$
	Гора	0	0	$\frac{1+0}{14+9}$	$\frac{1+0}{14+7}$
	Семь	0	0	$\frac{1+0}{14+9}$	$\frac{1+0}{14+7}$

Наивный байесовский классификатор

Задание. Определить, к какой категории отнести следующее письмо: «В магазине гора яблок. Купи семь килограмм и шоколадку».

Оценка для категории «Спам»:

$$\frac{2}{23} \times \frac{2}{23} \times \frac{1}{23} \times \frac{1}{23} \times \frac{1}{23} \times \frac{1}{23} \times \frac{1}{23} = 5,87E - 10$$

Оценка для категории «Не спам»:

$$\times \frac{2}{21} \times \frac{2}{21} \times \frac{2}{21} \times \frac{2}{21} \times \frac{1}{21} \times \frac{1}{21} \times \frac{1}{21} = 4,44E-9$$

	Слово	Кол-во вхождений в «Спам»	Кол-во вхождений в «Не спам»	$P(x_i \text{Спам})$	$P(x_i \text{Не спам})$
Слова из обучающей выборки	Путевки	1	0		
	Низкой	1	0		
	Цене	1	0		
	Акция	1	0		
	Купи	1	1	$\frac{1+1}{14+9}$	$\frac{1+1}{14+7}$
	Шоколадку	1	1	$\frac{1+1}{14+9}$	$\frac{1+1}{14+7}$
	Получи	1	0		
	Телефон	1	0		
	Подарок	1	0		
	Завтра	0	1		
	Состоится	0	1		
	Собрание	0	1		
	Килограмм	0	1	$\frac{1+0}{14+9}$	$\frac{1+1}{14+7}$
	Яблок	0	1	$\frac{1+0}{14+9}$	$\frac{1+1}{14+7}$
Слова из тестовой выборки	Магазине	0	0	$\frac{1+0}{14+9}$	$\frac{1+0}{14+7}$
	Гора	0	0	$\frac{1+0}{14+9}$	$\frac{1+0}{14+7}$
	Семь	0	0	$\frac{1+0}{14+9}$	$\frac{1+0}{14+7}$

ИТОГИ

Итоги занятия

- Основные задачи работы с текстом: машинный перевод, чат-боты, генерация текстов, проверка правописания, классификация/кластеризация текстов, извлечение информации
- Основные методы предобработки текстов: Counter, TF-IDF, Word2vec, эмбединги из языковых NN-моделей
- Коэффициент сходства — безразмерный показатель сходства сравниваемых объектов
- Мера семантической близости — это особая мера близости, предназначенная для количественной оценки семантической схожести лексем: существительных, многословных выражений
- Для работы с изображениями лучше всего подходит метод уменьшения размерности (PCA)
- Наивный байесовский классификатор — простой вероятностный классификатор, основанный на применении теоремы Байеса со строгими (наивными) предположениями о независимости

Работа со сложными данными

Алексей Кузьмин
Директор разработки в Домклик

