


Алгоритмы кластеризации

Алексей Кузьмин
Директор разработки в Домклик



Алексей Кузьмин

О спикере:

- директор разработки в Домклик
- руководил направлением работы с данными и машинного обучения
- под управлением ~600 человек
- экс-сотрудник АBBYY, где занимался распознаванием языков со сложной письменностью
- выпускник мехмата МГУ




План занятия

- 1 Задача кластеризации: постановка и примеры
- 2 Алгоритмы кластеризации
- 3 Метрики качества кластеризации

Задача кластеризации: постановка и примеры

Типы задач

- Классификация
- Ранжирование
- Регрессия
- **Кластеризация**



Примеры задач кластеризации

- **Пользовательская сегментация**

Как выглядят типичные пользователи? Находим секторы, работаем с ними отдельно

- **Логистика**

Где расположить магазины, чтобы охватить большее количество покупателей?

- **Новости**

О чём сейчас пишут СМИ? (Яндекс Новости кластеризуют новости и выдают их отдельными темами)

- **EDA**

Есть 100 млн обращений пользователей. О чём они пишут?

Дополнительные приложения

- **Создание дополнительных фич.** Можно дополнить имеющиеся данные метками принадлежности к одному из классов
- **Разметка данных.** Если нет проставленных классов, но нужно сделать классификатор, то в создании разметки для обучающей выборки сильно поможет кластеризация
- **Поиск структуры данных** как часть эксплоративного анализа

Дополнительные приложения

- **Сокращение объёма данных.** Сократить объём хранимых данных, оставив по одному представителю от каждого кластера (задачи сжатия данных)
- **Выделение нетипичных объектов.** Нетипичные объекты не подойдут ни одному из кластеров
- **Построение иерархии объектов** (задача таксономии).
Близкие объекты объединить в кластеры, потом мелкие кластеры — в более крупные и так далее

Постановка задачи



Каждому объекту поставить в пару метку кластера так, чтобы **близкие** объекты лежали в одном кластере, а далёкие — в разных.

Это математически некорректная задача, в ней есть неоднозначности и **нет правильного ответа**

$$X^{n \times k} \Rightarrow y^{n \times 1}$$

$$\rho : X \times X \rightarrow [0, \infty)$$


Кластеры могут быть очень разными




Кластеры могут быть очень разными



Масштаб признаков




А — студентки
В — студенты



после перенормировки
(сжали ось "вес" вдвое)


Алгоритмы кластеризации

Зачем много алгоритмов



Как и в других задачах:
разные алгоритмы лучше
справляются с разными
формами зависимостей

Шпаргалка по алгоритму scikit-learn



Типы кластеризации


- **Жёсткая** кластеризация: 1 объект — 1 класс
- **Мягкая (fuzzy)** кластеризация: 1 объект — несколько (или 0) классов
- **Иерархическая** кластеризация: объект внутри кластера 2.1 —> внутри кластера 2

Алгоритмы кластеризации

K-means (метод k-средних)

Алгоритм

- 1 Задать начальные значения центроидов кластеров
- 2 **Повторять, пока** центроиды смещаются:
 - присвоить наблюдениям номер кластера с **ближайшим** к ним центром
 - передвинуть центроиды кластеров к среднему значению координат членов кластера



Цель


Минимизировать внутриклассовые отличия от центроида:

$$\sum_{i=0}^n \min_{\mu_j} (\|x_i - \mu_j\|)^2$$

Связанные с этим проблемы:

- предположение о выпуклости и однородности кластеров
- проклятие размерности


Обновление назначений кластера



Ограничения

Алгоритм может выдавать контринтуитивные результаты:


- если указано не то число кластеров
- кластеры – не сферические и близко расположены
- разная дисперсия близких кластеров



Количество кластеров

Идея: перебирать от 1 до N кластеров, засечь, с какого момента качество перестанет быстро улучшаться.

Качество — сумма квадратов расстояний от точек до центроидов кластеров



Начальное приближение

Алгоритм очень зависит от начального приближения: метод сойдётся всегда, но к разным локальным минимумам.

Какие точки выбрать

- **Мультистарт:** N наборов начальных приближений, выбор лучшего
- **Наиболее удалённые друг от друга точки:**
 - удалить аномалии (посчитать среднее расстояние до q ближайших соседей, отбросить $\delta\%$ самых удалённых)
 - взять 2 самые дальние друг от друга точки, они составят множество U
 - $k-2$ раз добавлять в U по 1 точке, расстояние которой до ближайшей из старых точек U будет максимально большим


Ускорение. Семплирование

- 1 Провести кластеризацию N раз на N разных подмножествах
- 2 Посчитать функционал качества N полученных результатов на полной выборке, выбрать лучшее разбиение

Ускорение. Mini-batch k-means (мини-пакетный k-средних)

Способ: каждый шаг брать не все точки, а лишь подмножества (batch), обновляя центроиды как среднее признаков объектов кластера – как текущего, так и всех предыдущих шагов.

Результат: рост скорости с мизерным падением качества



Развитие. Мягкий вариант (ЕМ)

Более мягкий вариант k-means: каждому объекту ставить в соответствие не 1 кластер, а вектор близости к каждому кластеру.

Повторять, пока центроиды смещаются:

- оценить близость каждого объекта к каждому центроиду кластеров
- присвоить объектам номер кластера с ближайшим к ним центром
- передвинуть центроиды кластеров к **средневзвешенному** значению координат всех объектов, взвешивая по близости объекта к текущему центроиду кластера

Реализация в sklearn

sklearn.cluster.KMeans:

- `n_clusters=8`
- `init='k-means++'`
- `n_init=10`
- `max_iter=300`
- `tol=0.0001`
- `precompute_distances='auto'`
- `verbose=0`
- `random_state=None`
- `copy_x=True`
- `n_jobs=1`
- `algorithm='auto'`

Основные параметры:

- `n_clusters` — количество кластеров для разбиения
- `init`: 'k-means+', 'random', 'ndarray' — начальное приближение
- `max_iter` — количество итераций
- `n_jobs` — количество процессоров (-1 — max)

Основные характеристики:

- 11 параметров
- по умолчанию 10 начальных умных запусков на 1 процессоре, кластеризация на 8 групп



Основные методы:

- `fit`, `fit_predict`, `fit_transform`, `transform`, `predict`

Алгоритмы кластеризации

Hierarchical clustering (иерархическая кластеризация)

Идея




Алгоритм

Все объекты — отдельные кластеры.

Повторять, пока > 1 кластера:

- соединить 2 ближайших кластера




Пример

Дендрограмма кластеризации цветков ириса.


Проведена иерархическая кластеризация, визуализируемая в виде дендрограммы.

На картинке цветом линии отмечены 3 кластера, а цветом надписи — настоящий вид цветка



Расстояние между кластерами


- Ближнего соседа
- Дальнего соседа
- Групповое среднее
- Расстояние между центрами
- Расстояние Уорда



Расстояние между кластерами

- Ближнего соседа
- Дальнего соседа
- Групповое среднее
- Расстояние между центрами
- Расстояние Уорда


$$R^b(W, S) = \min_{w, s} \rho(w, s)$$



Расстояние между кластерами

- Ближнего соседа
- **Дальнего соседа**
- Групповое среднее
- Расстояние между центрами
- Расстояние Уорда


$$R^D(W, S) = \max_{w, s} \rho(w, s)$$



Расстояние между кластерами

- Ближнего соседа
- Дальнего соседа
- **Групповое среднее**
- Расстояние между центрами
- Расстояние Уорда


$$R^{\Gamma}(W, S) = \frac{1}{|W| * |S|} \sum_w \sum_s \rho(w, s)$$



Расстояние между кластерами

- Ближнего соседа
- Дальнего соседа
- Групповое среднее
- **Расстояние между центрами**
- Расстояние Уорда


$$R^{\text{ц}}(W, S) = \rho^2\left(\sum_w \frac{w}{|W|}, \sum_s \frac{s}{|S|}\right)$$



Расстояние между кластерами

- Ближнего соседа
- Дальнего соседа
- Групповое среднее
- Расстояние между центрами
- **Расстояние Уорда**

$$R^y(W, S) = \frac{|W| * |S|}{|W| + |S|} \rho^2 \left(\sum_w \frac{w}{|W|}, \sum_s \frac{s}{|S|} \right)$$



Свойства расстояний

Расстояние **монотонно**, если при каждом слиянии расстояние между кластерами растёт: $R_2 \leq R_3 \leq R_4 \dots$

Расстояние между центрами не монотонно. Остальные монотонны.

Расстояние **растягивающее**, если при каждом слиянии увеличение расстояний между кластерами растёт:

$$R_3 - R_2 \leq R_4 - R_3 \leq R_5 - R_4 \dots$$

Расстояние дальнего соседа и Уорда растягивающие

Рекомендуемое расстояние

Расстояние Уорда (Ward):

- монотонное
- растягивающее
- работает с центрами кластеров

Реализация в sklearn

AgglomerativeClustering:

- `n_clusters=2`
- `affinity='euclidean'`
- `memory=Memory(cachedir=None)`
- `connectivity=None`
- `compute_full_tree='auto'`
- `linkage='ward'`
- `pooling_func=<function mean>`

Основные параметры:

- `n_clusters` — количество кластеров для разбиения
- `linkage`: 'ward', 'complete', 'average'
- `affinity`:
 - 'euclidean', 'l1', 'l2', 'manhattan', 'cosine', 'precomputed' (для `linkage = 'ward'` доступно только евклидово)
- `connectivity` — априорные знания о структуре данных

Основные методы:

- `fit`, `fit_predict`


Алгоритмы кластеризации

DBSCAN — density-based spatial clustering of applications with noise (основанная на плотности пространственная кластеризация для приложений с шумами)

Идея

Рассматриваем объекты как ядра, вокруг которых собираются другие объекты.

Если не собираются — это выброс.
Если ядра связаны, то они и достижимые из них объекты образуют кластер




Идея

Все точки делятся на 3 типа:

- ядра (в ϵ -окрестности $\geq N$ точек)
- достижимые из ядра (в ϵ -окрестности $< N$ точек, > 0 ядер)
- выбросы (остальные)

Ядра и достижимые из них точки образуют кластеры. Выбросы не принадлежат ни одному кластеру



Реализация в sklearn

DBSCAN:

- `eps=0.5`
- `min_samples=5`
- `metric='euclidean'`
- `algorithm='auto'`
- `leaf_size=30`
- `p=None`
- `n_jobs=1`

Основные параметры:

- `eps` — размер окрестности
- `min_samples` — количество точек в окрестности ядра
- `n_jobs` — количество процессоров для расчёта (`-1-max`)

Основные методы:

- `fit`, `fit_predict`

Достоинства и недостатки

Достоинства:

- + обнаруживает выбросы
- + не нужно указывать количество кластеров
- + произвольная форма данных

Недостатки:

- сложно выбрать ϵ
- плохо работает с кластерами разной плотности

Алгоритмы кластеризации


Affinity propagation (метод распространения близости)

Идея

Объекты обмениваются двумя видами сообщений:

- насколько объект 1 готов быть экземпляром объекта 2
- насколько объект 2 готов предоставить право объекту 1 быть своим экземпляром

Итог: k -объектов — представителей кластеров



Алгоритм

Установить:

$$r(i, i) = 0, a(i, i) = 0$$

Повторять, пока
экземпляры меняются:


$$r(i, k) \leftarrow s(i, k) - \max_{k' \neq k} \{a(i, k') + s(i, k')\}$$

$$a(i, k) \leftarrow \min \left(0, r(k, k) + \sum_{i' \notin \{i, k\}} \max(0, r(i', k)) \right) \text{ for } i \neq k$$

$$a(k, k) \leftarrow \sum_{i' \neq k} \max(0, r(i', k)).$$

Итог: экземпляры с $r(i, i) + a(i, i) > 0$

Расчётное количество кластеров: 3



Реализация в sklearn

Affinity Propagation:

- damping=0.5
- max_iter=200
- convergence_iter=15
- copy=True
- preference=None
- affinity='euclidean'
- verbose=False

Основные параметры:

- preference – априорные знания о возможности быть экземпляром
- damping – скорость затухания [0,5–1]
- convergence_iter – условие останова, сколько должно пройти итераций без изменений


Основные методы:

- fit, fit_predict

Какой алгоритм выбрать

Имя метода	Параметры	Масштабируемость	Вариант использования	Геометрия (используемая метрика)
K-means	Количество кластеров	- Очень большая <code>n_samples</code> - Средняя <code>n_clusters</code> - С <code>Mini-batch code</code>	Универсальный, равномерный размер кластера, плоская геометрия, не слишком много кластеров	Расстояния между точками
Affinity propagation	Демпфирование, выбор образца	Не масштабируется с <code>n_samples</code>	Много кластеров, неравномерный размер кластера, неплоская геометрия	Расстояние графа (например, граф ближайшего соседа)
Agglomerative clustering	Количество кластеров, тип связи, расстояние	Большая <code>n_samples</code> и <code>n_clusters</code>	Много кластеров, возможно, ограничения связи, неевклидовы расстояния	Любое попарное расстояние
DBSCAN	Размер района	Очень большая <code>n_samples</code> , средняя <code>n_clusters</code>	Неплоская геометрия, неравные размеры кластеров	Расстояния между ближайшими точками

Метрики качества кластеризации



ARI: Adjusted Rand index (Скорректированный индекс Рэнда)

Дано:

- y_{pred} — вектор меток кластеризации $[0, 0, 0, 1, 1, 1]$
- y_{true} — реальные кластеры $[2, 2, 2, 7, 7, 7]$

$ARI \in [-1, 1];$

1 — точное соответствие

0 — случайное разбиение кластеров

$ARI(y_{\text{pred}}, y_{\text{true}}) = 1$

Метрике не важны названия кластеров

Silhouette (Силуэт)

Нет знания правильных кластеров.


Оценим, насколько сильно один объект сидит внутри своего кластера и насколько далеко от ближайшего соседнего:

$$s = \frac{b - a}{\max(a, b)}$$


$$s = \text{mean}(s)$$

- a — среднее расстояние до объектов внутри кластера
- b — среднее расстояние до объектов ближайшего кластера

Среднее значение по всем объектам — силуэт



Сравнение метрик



ARI	0,00	0,50	0,61	1,00
Silhouette	0,00	0,49	0,46	0,38

ИТОГИ

Итоги

- Кластеризация позволяет находить **структуру** в незамеченных данных, результаты кластеризации могут послужить **дополнительными признаками** для обучения или являться самостоятельной целью
- В задаче кластеризации **нет правильного решения**. Метрики качества служат лишь слабым приближением для создания новых алгоритмов или нахождения критерия останова
- Разные алгоритмы кластеризации принципиально **работают по-разному**, для конкретного набора данных необходимо выбирать наиболее подходящий

Полезные материалы

Полезные материалы

- [Документация sklearn](#) по кластеризации
- [Метрики sklearn](#) для задач кластеризации

Алгоритмы кластеризации

Алексей Кузьмин
Директор разработки в Домклик

